

# 运筹学与最优化课程设计

贾泽慧

南京信息工程大学 数学与统计学院

2022年12月2日

- 1 数学优化问题
- 2 数学优化模型
- 3 基本优化算法

# 数学优化问题：矩阵完备化(Matrix Completion)

- 问题：对于数据缺失、损坏等问题, 正确并高效地从不完整的、带有损毁的数据中恢复出完整的数据, 且假设高维数据间具有相关性和冗余性.

电影

	2		1			4				5	
	5		4				?		1		3
		3		5			2				
4			?			5		3		?	
	4		2	1	3				5		4
		1					1	?			
	2		?		5		?		5	4	
	3	3		1		5			2		1
	3			1							
	4			5	1			3			
		3				3	?			5	
2	?		1		1						
	5				2	?		4		4	
	1		3		1	5		4		5	
1		2			4				5	?	

用户

# 数学优化问题：矩阵完备化(Matrix Completion)

- 问题：对于数据缺失、损坏等问题, 正确并高效地从不完整的、带有损毁的数据中恢复出完整的数据, 且假设高维数据间具有相关性和冗余性.

电影

	2		1		4			5	
	5		4			?		1	3
		3		5		2			
4			?		5	3		?	
	4		1	3			5		4
		2				1	?		
	1				5		5	4	
		2		?	5		?	2	1
	3		3		1		5		
	3			1			2	3	
	4			5	1		3		
		3				3	?		5
2	?		1		1				
		5			2		?	4	4
	1		3		1	5		4	5
1		2		4				5	?

用户


- 优化模型:

$$\begin{aligned} \min_X \quad & \text{rank}(X) \\ \text{s.t.} \quad & X_{ij} = M_{ij}, (i, j) \in \Omega \end{aligned} \tag{1}$$

- 应用：推荐系统、社交网络等.


# 数学优化问题：压缩感知(Compressive Sensing)

- 问题：



# 数学优化问题：压缩感知(Compressive Sensing)

- 问题：




- 优化模型：

$$\begin{aligned} \min_x \quad & \|x\|_0 \\ \text{s.t.} \quad & Ax = b. \end{aligned} \tag{2}$$

# 数学优化问题：压缩感知(Compressive Sensing)

- 问题：




- 优化模型：

$$\begin{aligned} \min_x \quad & \|x\|_1 \\ \text{s.t.} \quad & Ax = b. \end{aligned} \tag{3}$$

# 数学优化问题：压缩感知(Compressive Sensing)

- 问题：



- 优化模型：

$$\begin{aligned} \min_x \quad & \|x\|_1 \\ \text{s.t.} \quad & Ax = b. \end{aligned} \tag{3}$$

- 应用：核磁共振成像、图像处理等领域.



# 数学优化问题：机器学习中的优化问题

- 文本分类

- 样本 $(x_i, y_i), i \in \{1, \dots, n\}$ ,  $x_i$ 对应文本特征,  $y_i$ 对应文本 $x_i$ 是否属于某类标签, 若属于则取1, 否则取-1.
- $h(x)$ 为预测函数,  $\ell(\cdot)$ 为度量函数.

# 数学优化问题：机器学习中的优化问题

- 文本分类

- 样本 $(x_i, y_i), i \in \{1, \dots, n\}$ ,  $x_i$ 对应文本特征,  $y_i$ 对应文本 $x_i$ 是否属于某类标签, 若属于则取1, 否则取-1.
- $h(x)$ 为预测函数,  $\ell(\cdot)$ 为度量函数.

$$R_n(h) = \frac{1}{n} \sum_{i=1}^n \ell[h(x_i) \neq y_i], \quad \ell[A] = \begin{cases} 1, & \text{if } A \text{ is true,} \\ 0, & \text{otherwise.} \end{cases}$$

# 数学优化问题：机器学习中的优化问题

- 文本分类

- 样本 $(x_i, y_i), i \in \{1, \dots, n\}$ ,  $x_i$ 对应文本特征,  $y_i$ 对应文本 $x_i$ 是否属于某类标签, 若属于则取1, 否则取-1.
- $h(x)$ 为预测函数,  $\ell(\cdot)$ 为度量函数.

$$R_n(h) = \frac{1}{n} \sum_{i=1}^n \ell[h(x_i) \neq y_i], \quad \ell[A] = \begin{cases} 1, & \text{if } A \text{ is true,} \\ 0, & \text{otherwise.} \end{cases}$$

$$h^{\text{rote}}(x) = \begin{cases} y_i, & \text{if } x = x_i \text{ for some } i \in \{1, \dots, n\}, \\ \pm 1, & \text{otherwise.} \end{cases}$$

# 数学优化问题：机器学习中的优化问题

- 文本分类

- 样本 $(x_i, y_i), i \in \{1, \dots, n\}$ ,  $x_i$ 对应文本特征,  $y_i$ 对应文本 $x_i$ 是否属于某类标签, 若属于则取1, 否则取-1.
- $h(x)$ 为预测函数,  $\ell(\cdot)$ 为度量函数.

$$R_n(h) = \frac{1}{n} \sum_{i=1}^n \ell[h(x_i) \neq y_i], \quad \ell[A] = \begin{cases} 1, & \text{if } A \text{ is true,} \\ 0, & \text{otherwise.} \end{cases}$$

$$h^{\text{rote}}(x) = \begin{cases} y_i, & \text{if } x = x_i \text{ for some } i \in \{1, \dots, n\}, \\ \pm 1, & \text{otherwise.} \end{cases}$$

$$h(x; w, \tau) = w^T x - \tau.$$

# 数学优化问题：机器学习中的优化问题

- 优化模型

$$\min_{(w, \tau) \in \mathcal{R}^d \times \mathcal{R}} \frac{1}{n} \sum_{i=1}^n \ell(h(x_i; w, \tau), y_i) + \frac{\lambda}{2} \|w\|_2^2$$

$$\ell(h, y) = \log(1 + \exp(-hy)) \quad \text{log-loss function}$$

$$\ell(h, y) = \max(0, 1 - hy) \quad \text{hinge loss function}$$

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h_i(x) \leq 0, \quad i = 1, \dots, m, \\ & g_j(x) = 0, \quad j = 1, \dots, p. \end{aligned} \tag{4}$$

- $x \in \mathcal{R}^n$  为决策变量
- $f : \mathcal{R}^n \rightarrow \mathcal{R}$  为目标函数
- $h_i : \mathcal{R}^n \rightarrow \mathcal{R}, i = 1, \dots, m$  为不等式约束函数
- $g_j : \mathcal{R}^n \rightarrow \mathcal{R}, j = 1, \dots, p$  为等式约束函数
- $\Omega = \{x \in \mathcal{R}^n \mid h_i(x) \leq 0, \quad i = 1, \dots, m; \quad g_j(x) = 0, \quad j = 1, \dots, p\}$  为可行域

## 线性优化

$$\begin{array}{ll} \min_x & \langle c, x \rangle \\ \text{s.t.} & Ax = b \leq 0, \\ & x \geq 0. \end{array} \quad (5)$$

- 求解方法：单纯形法、内点算法等。

## 非线性无约束优化

$$\begin{array}{ll}\min_x & f(x) \\ \text{s.t.} & x \in \mathcal{R}^n\end{array}$$

- 针对无约束优化问题，常用收敛准则

$$\frac{f(x^k) - f^*}{\max\{|f^*|, 1\}} \leq \epsilon_1, \quad \|\nabla f(x^k)\| \leq \epsilon_2,$$

其中 $\epsilon_1, \epsilon_2$ 为给定的很小的正数， $f^*$ 为函数 $f$ 的最小值（假设已知或者以某种方式估计得到）以及 $\nabla f(x^k)$ 表示函数 $f$ 在点 $x^k$ 处的梯度（光滑函数在局部最优点处梯度为零向量）。

- 针对无约束优化问题，常用停机准则

$$\frac{\|x^{k+1} - x^k\|}{\max\{\|x^k\|, 1\}} \leq \epsilon_3, \quad \frac{|f(x^{k+1}) - f(x^k)|}{\max\{|f(x^k)|, 1\}} \leq \epsilon_4$$

其中 $\epsilon_3, \epsilon_4$ 为给定的很小的正数。



# 数学优化算法

- 收敛速度:

设 $\{x^k\}$ 为算法产生的迭代点列且收敛于 $x^*$ , 若对充分大的 $k$ 有

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} \leq a, \quad a \in (0, 1),$$

则称算法（点列）是Q-线性收敛的；若满足

$$\lim_{k \rightarrow \infty} \frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|} = 0,$$

称算法（点列）是Q-超线性收敛的；若满足

$$\frac{\|x^{k+1} - x^*\|}{\|x^k - x^*\|^2} \leq a, \quad a > 0,$$

则称算法（点列）是Q-二次收敛的.

## 非线性无约束优化 ( $f$ 光滑)

$$\begin{array}{ll} \min_x & f(x) \\ \text{s.t.} & x \in \mathcal{R}^n \end{array} \quad (6)$$

- 梯度下降法

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k) \quad (7)$$

$$x^{k+1} = \arg \min_x \left\{ f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\alpha_k} \|x - x^k\|^2 \right\}$$

## 非线性无约束优化 ( $f$ 光滑)

$$\begin{array}{ll}\min_x & f(x) \\ \text{s.t.} & x \in \mathcal{R}^n\end{array}\quad (6)$$

- 梯度下降法

$$x^{k+1} = x^k - \alpha_k \nabla f(x^k) \quad (7)$$

$$x^{k+1} = \arg \min_x \{f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2\alpha_k} \|x - x^k\|^2\}$$

- $\alpha_k = \arg \min_{\alpha} \{f(x^k - \alpha \nabla f(x^k))\}$
- $\alpha_k = \frac{s^{kT} s^k}{s^{kT} y^k}$ , 其中  $s^k = x^k - x^{k-1}$ ,  $y^k = \nabla f(x^k) - \nabla f(x^{k-1})$

# 数学优化算法

- 定理(梯度下降法在凸函数上的收敛性)

设函数 $f(x)$ 为凸的梯度 $L$ -利普希茨连续函数,  $f^* = f(x^*) = \inf_x f(x)$ 存在且可达. 如果步长 $\alpha_k$ 取为满足 $0 < \alpha < \frac{1}{L}$ 的常数, 那么由梯度下降法得到的点列 $\{x^k\}$ 的函数值收敛到最优值, 且在函数值的意义下收敛速度为 $O(\frac{1}{k})$ , 也就是说

$$f(x^k) - f^* \leq O(\frac{1}{k}).$$

- 定理(梯度下降法在强凸函数上的收敛性)

设函数 $f(x)$ 为 $m$ -强凸的梯度 $L$ -利普希茨连续函数,  $f^* = f(x^*) = \inf_x f(x)$ 存在且可达. 如果步长 $\alpha_k$ 取为满足 $0 < \alpha < \frac{1}{m+L}$ 的常数, 那么由梯度下降法迭代得到的点列 $\{x^k\}$ 的函数值收敛到最优值, 且为 $Q$ -线性收敛.

## 非线性无约束优化 ( $f$ 光滑)

$$\begin{array}{ll} \min_x & f(x) \\ \text{s.t.} & x \in \mathcal{R}^n \end{array} \quad (8)$$

- 牛顿法

$$x^{k+1} = x^k - [\nabla^2 f(x^k)]^{-1} \nabla f(x^k) \quad (9)$$

$$x^{k+1} = \arg \min_x \{f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k)\}$$

- 定理(牛顿法的收敛性)

设目标函数 $f$ 二阶连续可微, 且海瑟矩阵在最优值点 $x^*$ 的一个邻域 $N_\delta(x^*)$ 内是利普希茨连续的. 如果函数 $f(x)$ 在 $x^*$ 处满足

$$\nabla f(x^*) = 0, \nabla^2 f(x^*) \succeq 0,$$

则对于牛顿法有如下结论:

- (1) 如果初始点离 $x^*$ 足够近, 则迭代点列 $\{x^k\}$ 收敛到 $x^*$ ;
- (2) 收敛到 $x^*$ 的速度是 $Q$ -二次的;
- (3)  $\{\|\nabla f(x^k)\|\}$   $Q$ -二次收敛到0.

## 非线性无约束优化 ( $f$ 光滑)

$$\begin{array}{ll}\min_x & f(x) \\ \text{s.t.} & x \in \mathcal{R}^n\end{array}\quad (10)$$

- 拟牛顿法

$$x^{k+1} = x^k - \alpha_k H_k \nabla f(x^k) \quad (11)$$

- $H_k$ 更新方式：秩一更新、BFGS公式、DFP等。
- BFGS更新公式：

$$B_{k+1} = B_k + \frac{y^k (y^k)^T}{(s^k)^T y^k} - \frac{B_k s^k (B_k s^k)^T}{(s^k)^T B_k s^k}, \quad B_k = H_k^{-1},$$

其中  $s^k = x^{k+1} - x^k$ ,  $y^k = \nabla f(x^{k+1}) - \nabla f(x^k)$ 。

- 定理(BFGS收敛性)

设目标函数 $f$ 是二阶连续可微的函数, 且海瑟矩阵在最优值点 $x^*$ 的一个邻域 $N_\delta(x^*)$ 内是利普希茨连续的. 且使用BFGS迭代格式收敛到 $f$ 的最优值点 $x^*$ . 若点列 $\{x^k\}$ 满足

$$\sum_{k=1}^{\infty} \|x^{k+1} - x^k\| < \infty,$$

则 $\{x^k\}$   $Q$ -超线性收敛到 $x^*$ .



## 非线性无约束优化 ( $f$ 非光滑)

$$\begin{array}{ll} \min_x & f(x) \\ \text{s.t.} & x \in \mathcal{R}^n \end{array} \quad (12)$$

- 邻近点算法(PPA)

$$x^{k+1} = \arg \min_x \{f(x) + \frac{1}{2\alpha_k} \|x - x^k\|^2\} := \text{prox}_{\alpha_k f}(x^k)$$

- 定理(PPA的收敛性)

设目标函数 $f$ 是适当的闭凸函数,  $f$ 的最小值存在且可以达到, 设 $\{x^k\}$ 是由PPA产生的序列, 则

$$f(x^k) - f(x^*) \leq \frac{1}{2 \sum_{i=1}^k \alpha_i} \|x^0 - x^*\|^2.$$

## 非线性无约束优化 ( $f$ 光滑, $g$ 非光滑)

$$\begin{aligned} \min_x \quad & F(x) = f(x) + g(x) \\ \text{s.t.} \quad & x \in \mathcal{R}^n \end{aligned} \tag{13}$$

- 邻近梯度算法(PGA)

$$\begin{aligned} x^{k+1} &= \arg \min_x \{f(x^k) + \langle \nabla f(x^k), x - x^k \rangle + g(x) + \frac{1}{2\alpha_k} \|x - x^k\|^2\} \\ &:= \text{prox}_{\alpha_k g}(x^k - \alpha_k \nabla f(x^k)) \end{aligned}$$

- 定理(PGA的收敛性)

设函数 $f(x)$ 为凸的梯度 $L$ -利普希茨连续函数,  $h$ 是适当的闭凸函数,  $F$ 的最小值存在且可以达到, 设 $\{x^k\}$ 是由PGA产生的序列, 则 $F(x^k) - F(x^*) \leq \frac{1}{2k\alpha} \|x^0 - x^*\|^2$ .

## 非线性无约束优化 ( $f$ 光滑)

$$\begin{array}{ll} \min_x & f(x) = \sum_{i=1}^n f_i(x) \\ \text{s.t.} & x \in \mathcal{R}^n \end{array} \quad (14)$$

- 随机梯度法

$$x^{k+1} = x^k - \alpha_k \nabla f_{i_k}(x^k) \quad (15)$$

$$x^{k+1} = \arg \min_x \{f(x^k) + \langle \nabla f_{i_k}(x^k), x - x^k \rangle + \frac{1}{2\alpha_k} \|x - x^k\|^2\}$$

## 非线性无约束优化 ( $f$ 光滑)

$$\begin{array}{ll}\min_x & f(x) = \sum_{i=1}^n f_i(x) \\ \text{s.t.} & x \in \mathcal{R}^n\end{array}\quad (16)$$

- mini-batch 随机梯度法

$$x^{k+1} = x^k - \alpha_k \sum_{i \in B_k} \nabla f_i(x^k) \quad (17)$$

$$x^{k+1} = \arg \min_x \left\{ f(x^k) + \left\langle \sum_{i \in B_k} \nabla f_i(x^k), x - x^k \right\rangle + \frac{1}{2\alpha_k} \|x - x^k\|^2 \right\}$$

- 方差缩减随机梯度法(SVRG,SAGA,SARAH,SPIDER...)

- 定理(随机梯度法的收敛性)

假设目标函数 $f$ 是 $\mu$ -强凸函数且梯度 $L$ -李普希茨连续, 随机梯度二阶矩是一致有界的, 即

$$\mathbb{E}_{i_k} [\|\nabla_{i_k} f(x)\|^2] \leq M^2 < +\infty,$$

固定步长 $0 < \alpha < \frac{1}{2\mu}$ , 序列 $\{x^k\}$  由随机梯度法产生, 则

$$\begin{aligned}\mathbb{E}[f(x^k) - f(x^*)] &\leq \frac{L}{2} \mathbb{E}\|x^k - x^*\|^2 \\ &\leq \frac{L}{2} \left( (1 - 2\alpha\mu)^k \|x^1 - x^*\|^2 + \frac{\alpha M^2}{2\mu} \right).\end{aligned}$$

- 定理(随机梯度法的收敛速度)

在上一定理的结果中取递减的步长 $\alpha_k = \frac{\beta}{k+\gamma}$ , 其中 $\gamma \geq \frac{1}{2\mu}$ ,  $\gamma > 0$ 使得 $\alpha_1 \leq \frac{1}{2\mu}$ , 那么对于任意的 $k \geq 1$ 都有

$$\mathbb{E}[f(x^k) - f(x^*)] \leq \frac{L}{2} \mathbb{E}\|x^k - x^*\|^2 \leq \frac{L}{2} \frac{v}{\gamma + k},$$

$$\text{其中 } v = \max \left\{ \frac{\beta^2 M^2}{2\beta\mu - 1}, (\gamma + 1)\Delta_1^2 \right\}.$$

# 课程设计题目

- 基追踪问题

基追踪问题是压缩感知中的一个基本问题，可以写为

$$\begin{aligned} \min_x \quad & \|x\|_1 \\ \text{s.t.} \quad & Ax = b, \end{aligned}$$

其中  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^n$ ,  $x \in \mathbb{R}^n$  为待求解的变量. 可考虑其对偶问题将该约束优化问题转化为一个无约束优化问题, 但由于此问题的对偶问题的无约束优化形式不是可微的, 即无法计算梯度, 故考虑如下正则化问题:

$$\begin{aligned} \min_x \quad & \|x\|_1 + \frac{1}{2\alpha} \|x\|^2 \\ \text{s.t.} \quad & Ax = b, \end{aligned}$$

其中  $\alpha$  为正则化参数,

# 课程设计题目

- 正则化的基追踪问题的对偶问题为

$$\min -b^T y + \frac{\alpha}{2} \|A^T y - P_{[-1,1]^n}(A^T y)\|_2^2$$

其中  $P_{[-1,1]^n}$  表示到集合  $[-1, 1]^n$  的投影,  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^n$ ,  $\alpha$  为已知参数,  $y \in \mathbb{R}^m$  为待求解的变量。

- 练习

- (1) 阐述压缩感知问题的发展及其应用背景;
- (2) 介绍一种求解基追踪问题的对偶问题的优化算法, 并给出算法的收敛结果;
- (3) 作图展示算法的求解结果 (迭代序列与最优解之间的距离随迭代步数的变化图), 并对算法的求解结果进行对比、总结、分析。



- LASSO问题

LASSO(Least absolute shrinkage and selection operator)问题是一个经典的稀疏优化问题，其通过二次罚函数将基追踪问题表述为一个无约束优化问题，具体形式可以表述为

$$\min_x f(x) = \frac{1}{2} \|Ax - b\|^2 + \mu \|x\|_1,$$

其中 $x \in \mathbb{R}^n$ ,  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^n$ ,  $\mu > 0$ 为已知参数，且向量 $b$ 的维数远小于向量 $x$ 的维数，即 $m \ll n$ ，表示向量 $x$ 的每个元素的绝对值之和。LASSO通过惩罚参数的 $l_1$ 范数来控制解的稀疏性，如果 $x$ 是稀疏的，那么预测值 $b_i$ 只和矩阵 $A$ 的行向量 $a_i$ 的部分元素相关。。

- 练习

针对上述LASSO问题，

- (1) 阐述LASSO问题的发展及其应用背景；
- (2) 介绍梯度算法、邻近梯度算法，并给出算法的收敛结果；
- (3) 采用梯度法（需对目标函数进行光滑化处理）或邻近梯度算法对LASSO问题进行求解；
- (4) 作图展示算法的求解结果（目标函数值随迭代步数的变化图），并对算法的求解结果进行对比、总结、分析。

- 低秩矩阵恢复

低秩矩阵恢复模型想要构造一个矩阵 $X$ ，使得其在给定位置的元素等于想要恢复的矩阵 $M$ 的元素，但是只知道矩阵 $M$ 在下标集 $\Omega$ 上的值，该模型具体形式为

$$\min_{M \in \mathbb{R}^{m \times n}} \mu \|X\|_* + \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2,$$

其中 $\mu$ 为已知参数， $\|X\|_*$ 为核范数，表示矩阵 $X$ 的奇异值的和，用于保证矩阵的低秩性，而范数平方项可保证矩阵 $X$ 与想要恢复的矩阵 $M$ 的元素对应相等。

- 练习

令  $f(x) = \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - M_{ij})^2$ ,  $g = \mu \|x\|_*$ ,

- (1) 阐述低秩矩阵恢复问题的发展及其应用背景;
- (2) 介绍邻近梯度算法, 并给出算法的收敛结果;
- (3) 作图展示算法的求解结果 (函数值随迭代步数的变化图), 并对算法的求解结果进行对比、总结、分析。

- 逻辑回归

逻辑回归模型，其在线性回归的基础上，继续套用了一层函数，用于解决二分类问题，并因其简单性、可并行化、可解释性强深受各界喜爱。下面给出其对应的优化问题

$$\min_x \frac{1}{m} \sum_{i=1}^m \ln(1 + \exp(-b_i a_i^T x)) + \lambda \|x\|^2,$$

其中  $\lambda = \frac{1}{100m}$ ， $a_i$ ， $b_i$  为已知的待分类的数据集， $x$  为待求解的变量。

- 练习

- (1)阐述逻辑回归问题的发展及其应用背景，并将逻辑回归与其他分类方法对比（如支持向量机等）指出其优缺点；
- (2)介绍一种求解该问题的优化算法，并给出收敛结果；
- (3)作图展示算法的求解结果（目标函数值或梯度范数随迭代步数的变化图），并对算法的求解结果进行对比、总结、分析。

Thank you!